Transcription as Interpretation

Review

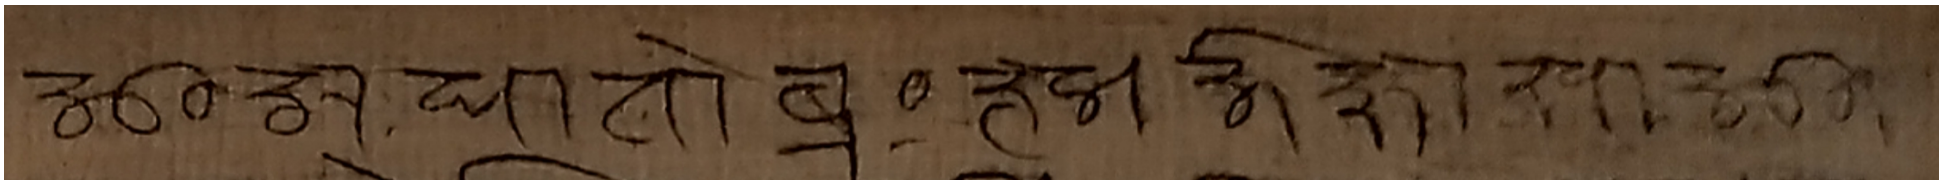
- discuss any issues/questions/successes/failures about regular expressions
- show & tell any monstrous regexes you've come up with

Today

- what we do when we do transcription
- Unicode
- IIIF
- let’s start transcribing!

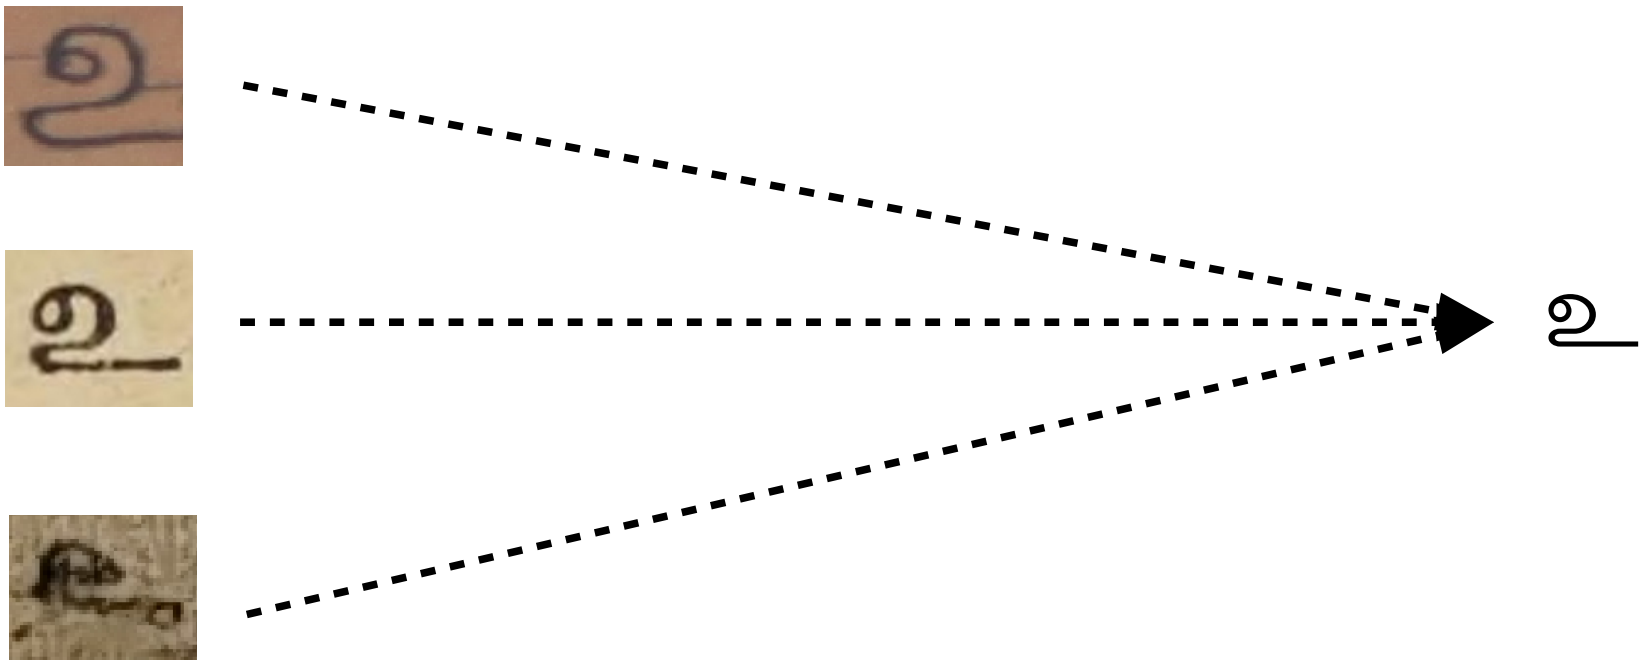
…In that Empire, the craft of Cartography attained such Perfection that the Map of a Single province covered the space of an entire City, and the Map of the Empire itself an entire Province. In the course of Time, these Extensive maps were found somehow wanting, and so the College of Cartographers evolved a Map of the Empire that was of the same Scale as the Empire and that coincided with it point for point. Less attentive to the Study of Cartography, succeeding Generations came to judge a map of such Magnitude cumbersome, and, not without Irreverence, they abandoned it to the Rigors of sun and Rain. In the western Deserts, tattered Fragments of the Map are still to be found, Sheltering an occasional Beast or beggar; in the whole Nation, no other relic is left of the Discipline of Geography.

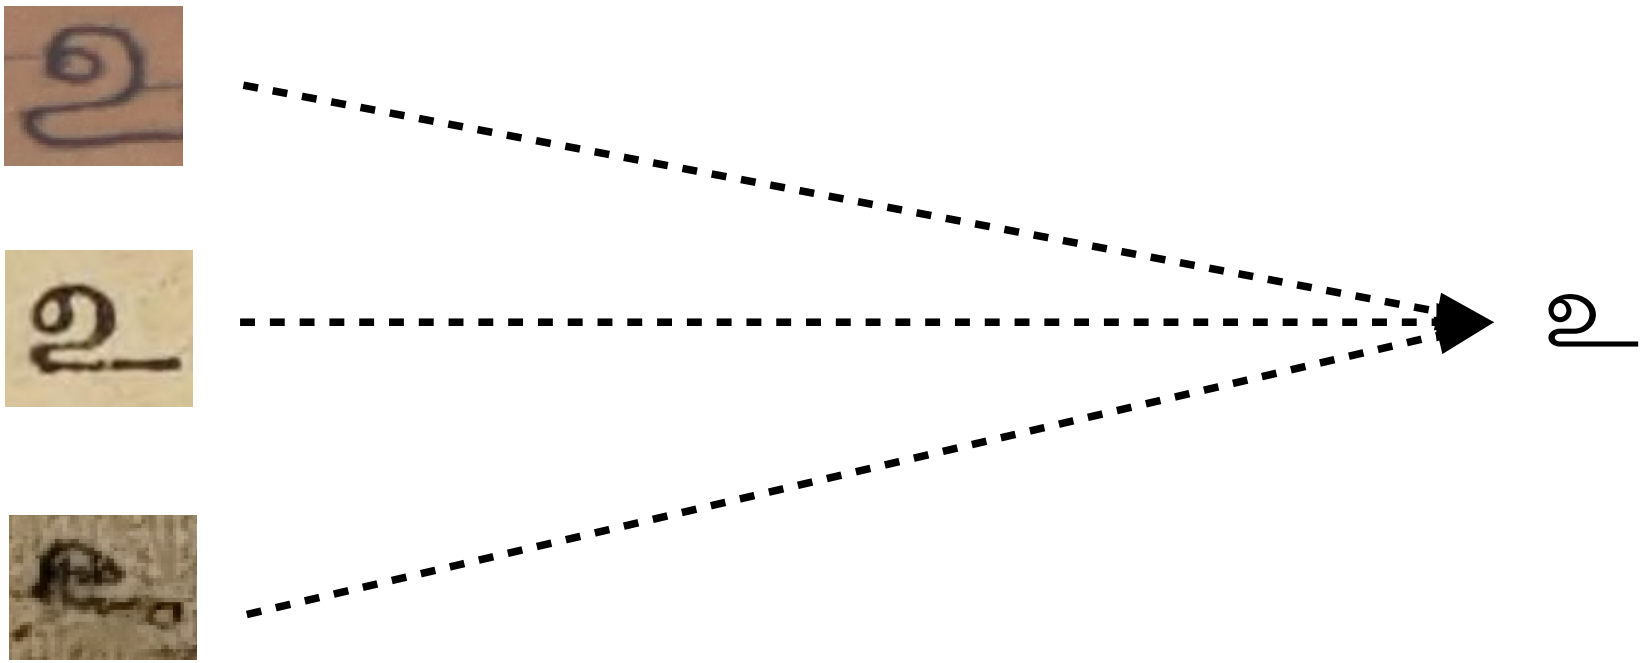
Jorge Luis Borges, trans. di Giovanni 1972, 141.



ॐ ष्ठाघातो ब्रंह्मऽझिज्ञासा ॐ ।

BnF Sanscrit 1146, 1r.



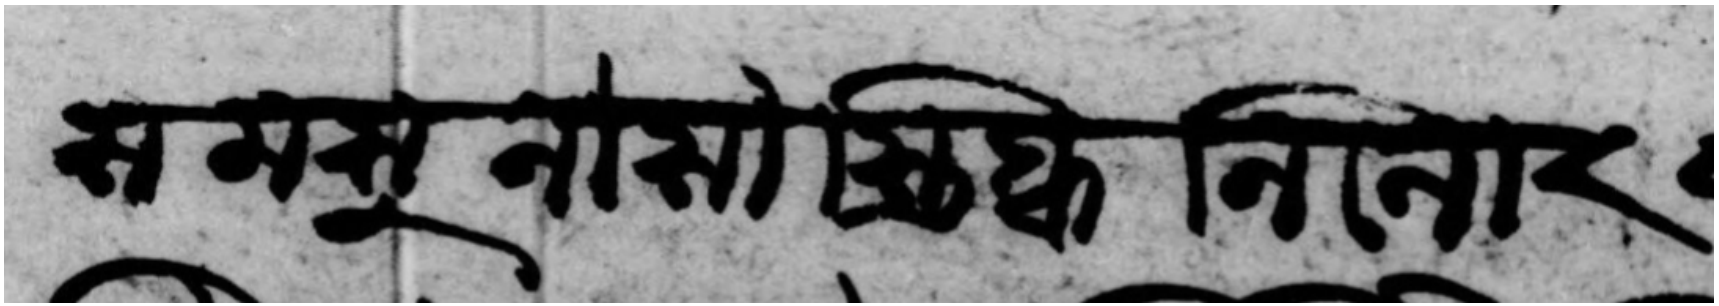


yadi punar ime varṇā ādityavat syuḥ |

Mahābhāṣya, ed. Kielhorn 1892, I, 18.

What if these sounds were like the sun?

স

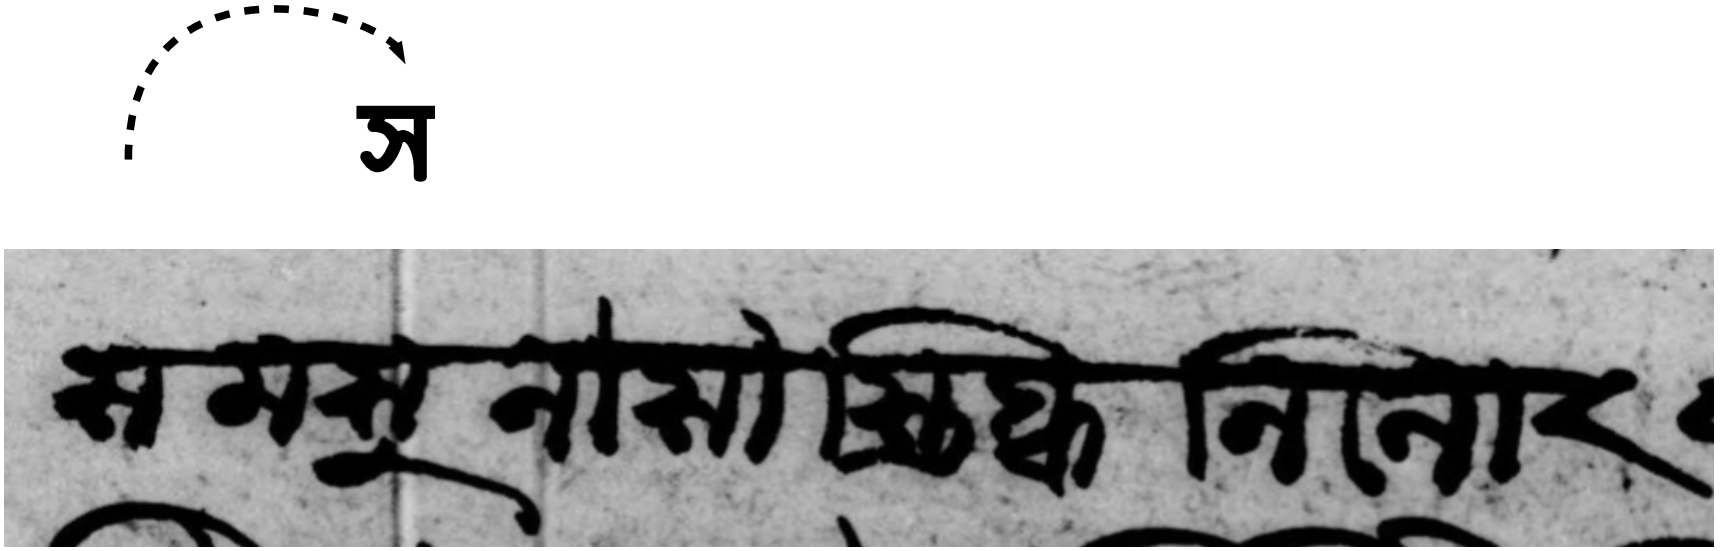


BnF Sanscrit 756, 4r.

yadi punar ime varṇāḥ śakunivat syuḥ |

Mahābhāṣya, ed. Kielhorn 1892, I, 18.

What if these sounds were like birds?

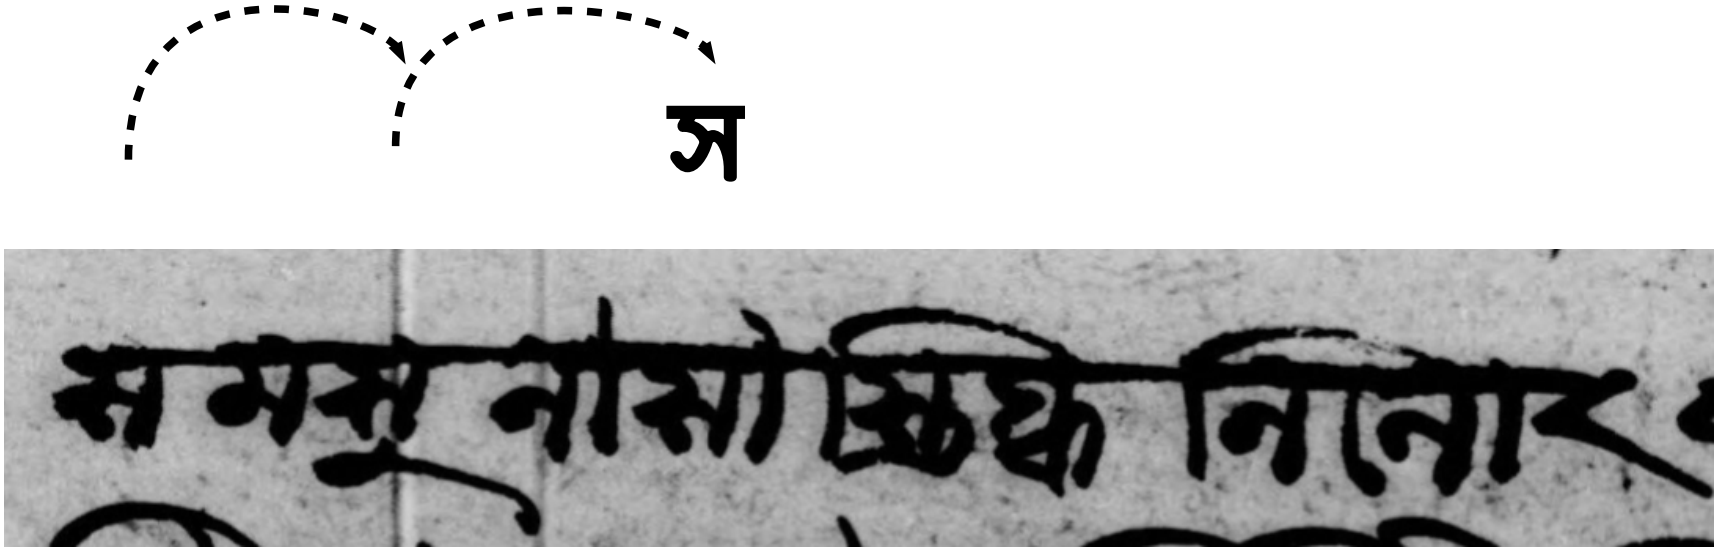


BnF Sanscrit 756, 4r.

yadi punar ime varṇāḥ śakunivat syuḥ |

Mahābhāṣya, ed. Kielhorn 1892, I, 18.

What if these sounds were like birds?

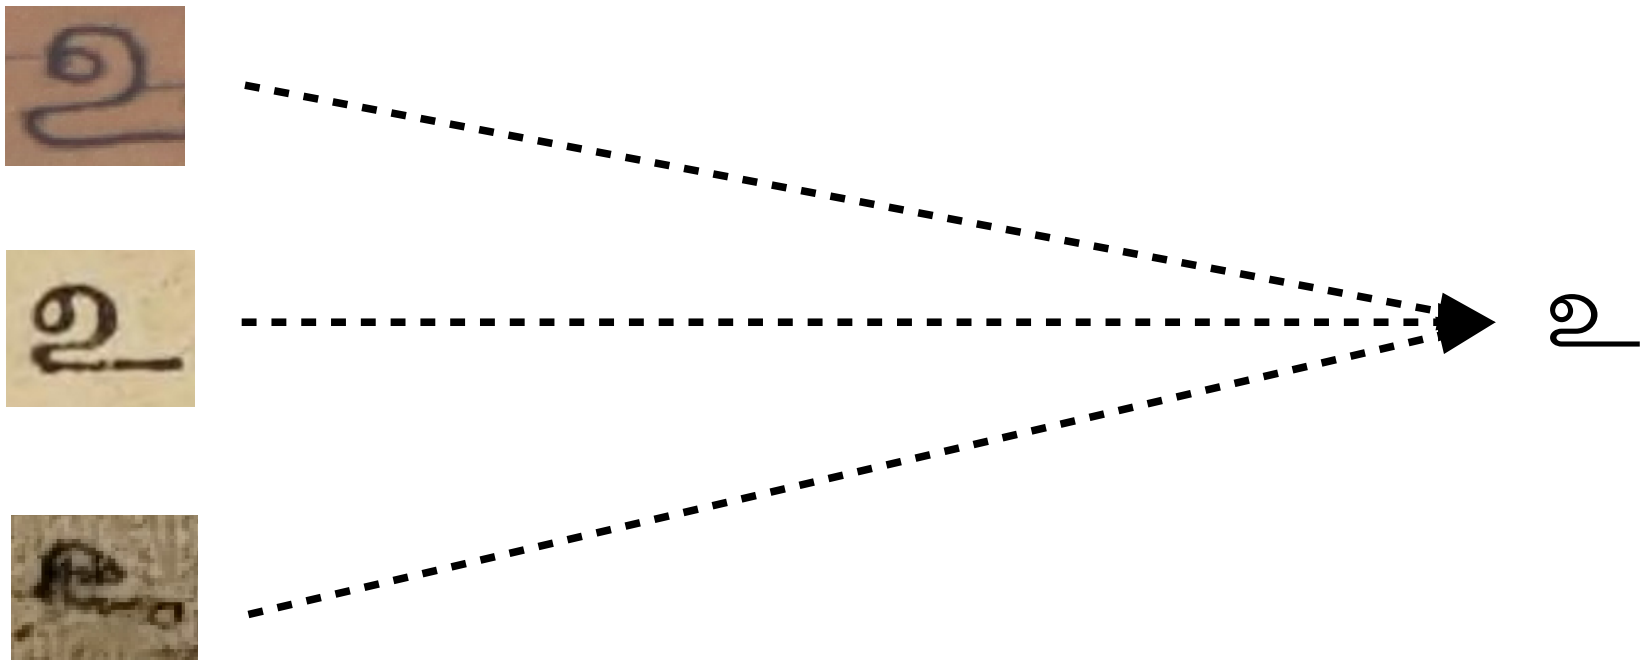


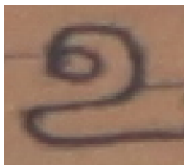
BnF Sanscrit 756, 4r.

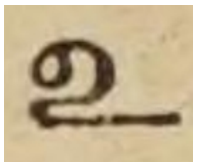
yadi punar ime varṇāḥ śakunivat syuḥ |

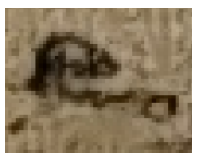
Mahābhāṣya, ed. Kielhorn 1892, I, 18.

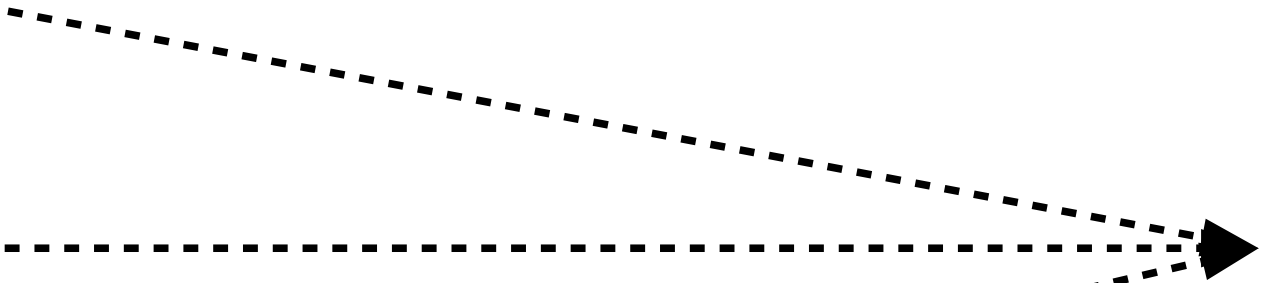
What if these sounds were like birds?



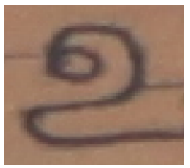
Malayalam 

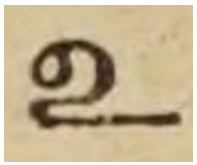
Tamil 

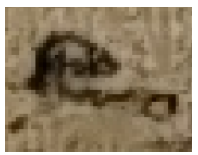
Grantha 





Malayalam  ⟶ ഉ

Tamil  ⟶ உ

Grantha  ⟶ உ

உ 4/20

காலமானார்.

அண்மைய இறப்புகள்: தேவா • சிங்கீதம் சீனிவாசராவ் • மு. சிவலிங்கம்

தொடர் நிகழ்வுகள்: 2026 ஈரான் போர் • பிற நிகழ்வுகள்

உங்களுக்குத் தெரியுமா?



- மகாசுதங்கர் (படம்) கிமு 260-இல் அசோகர் நிறுவிய கல்வெட்டுகள் கொண்ட பௌத்த தொல்லியல் களம். வங்காளதேசத்தில் அமைந்துள்ளது. 1931-ஆம் ஆண்டில் கண்டுபிடிக்கப்பட்ட இக்கல்வெட்டில் அசோகர் நிலம் தானமாகக் கொடுத்தது பற்றிக் குறிக்கப்பட்டுள்ளது.
- பெருந்தோற்றத்திற்கான முக்கியமான காரணம், மூளையில் உள்ள "கபச் சுரப்பி" எனப்படும் சுரப்பி அதிக அளவில் வளர்ச்சி இயக்குநீரைச் சுரப்பது ஆகும்.
- அரச பயங்கரவாதம் எனும் சொல் ஓர் அரசாங்கம் தமது நாட்டில் தமது மக்கள் மீதே கட்டவிழ்த்துவிடும் பயங்கரவாத நடவடிக்கைகளைக் குறிக்கும்.
- போகர் என்பவர் பதினெண் சித்தர்களுள் தனிச்

உ 0/0

காலமானார்.

அண்மைய இறப்புகள்: தேவா • சிங்கீதம் சீனிவாசராவ் • மு. சிவலிங்கம்

தொடர் நிகழ்வுகள்: 2026 ஈரான் போர் • பிற நிகழ்வுகள்

உங்களுக்குத் தெரியுமா?



- மகாசுதங்கர் (படம்) கிமு 260-இல் அசோகர் நிறுவிய கல்வெட்டுகள் கொண்ட பௌத்த தொல்லியல் களம். வங்காளதேசத்தில் அமைந்துள்ளது. 1931-ஆம் ஆண்டில் கண்டுபிடிக்கப்பட்ட இக்கல்வெட்டில் அசோகர் நிலம் தானமாகக் கொடுத்தது பற்றிக் குறிக்கப்பட்டுள்ளது.
- பெருந்தோற்றத்திற்கான முக்கியமான காரணம், மூளையில் உள்ள "கபச் சுரப்பி" எனப்படும் சுரப்பி அதிக அளவில் வளர்ச்சி இயக்குநீரைச் சுரப்பது ஆகும்.
- அரச பயங்கரவாதம் எனும் சொல் ஓர் அரசாங்கம் தமது நாட்டில் தமது மக்கள் மீதே கட்டவிழ்த்துவிடும் பயங்கரவாத நடவடிக்கைகளைக் குறிக்கும்.
- போகர் என்பவர் பதினெண் சித்தர்களுள் தனிச்

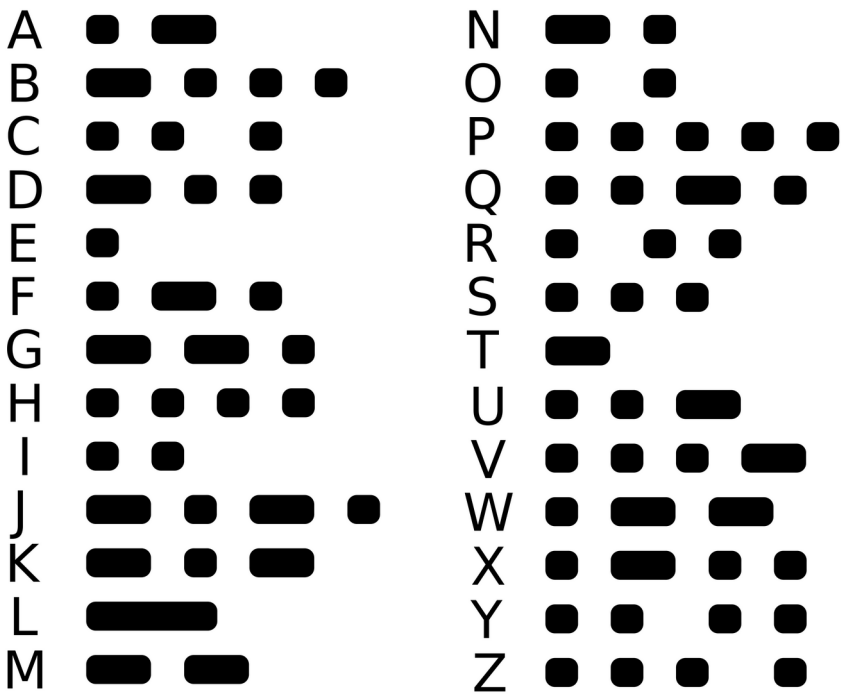
ta.wikipedia.org

Unicode

“We provide a unique code for every character, in every language, in every program, on every platform.”

home.unicode.org/basic-info/overview

Unicode



American Morse Code, Wikimedia.

Unicode

Version 1.0.0 (1991)

[null]	0	U+0000
[start of heading]	1	U+0001
[start of text]	2	U+0002
…		
A	65	U+0041
B	66	U+0042
C	67	U+0043

Unicode

Version 1.0.0 (1991)

A	65	U+0041
B	66	U+0042
C	67	U+0043
…		
अ	2309	U+0905
आ	2310	U+0906
इ	2311	U+0907

Unicode

Version 1.0.0 (1991)

अ	2309	U+0905
आ	2310	U+0906
इ	2311	U+0907
…		
அ	2949	U+0B85
ஆ	2950	U+0B86
இ	2951	U+0B87

Unicode

Version 3.0 (1999)

က	4096	U+1000
ခ	4097	U+1001
ဂ	4098	U+1002
…		
ሀ	4608	U+1200
ሁ	4609	U+1201
ሂ	4610	U+1202

Unicode

Version 6.0 (2010)

	128512	U+1F600
	128513	U+1F601
	128514	U+1F602
…		
	128571	U+1F63B
	128572	U+1F63C
	128573	U+1F63D

Unicode

Version 7.0 (2014)

𑌅	70405	U+11305
𑌆	70406	U+11306
𑌇	70407	U+11307
…		
𑌠	70656	U+11400
𑌡	70657	U+11401
𑌢	70658	U+11402

Unicode

Regex \w (word character)

ideal

Includes	Excludes
a ā ಹಾ ঞ ന ሄ	: + - ¦ ९ 😸

Unicode

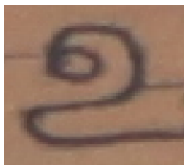
Regex \w (word character)

ideal

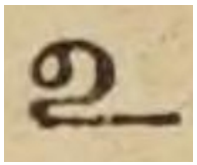
Includes	Excludes
a ā ಹಾ ञ् ന ሄ	: + - ¦ ९ 😺

reality (depending on software)

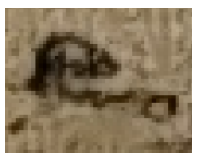
Includes	Excludes
a	ā ಹಾ ञ् ന ሄ : + - ¦ ९ 😺

Malayalam  ഉ

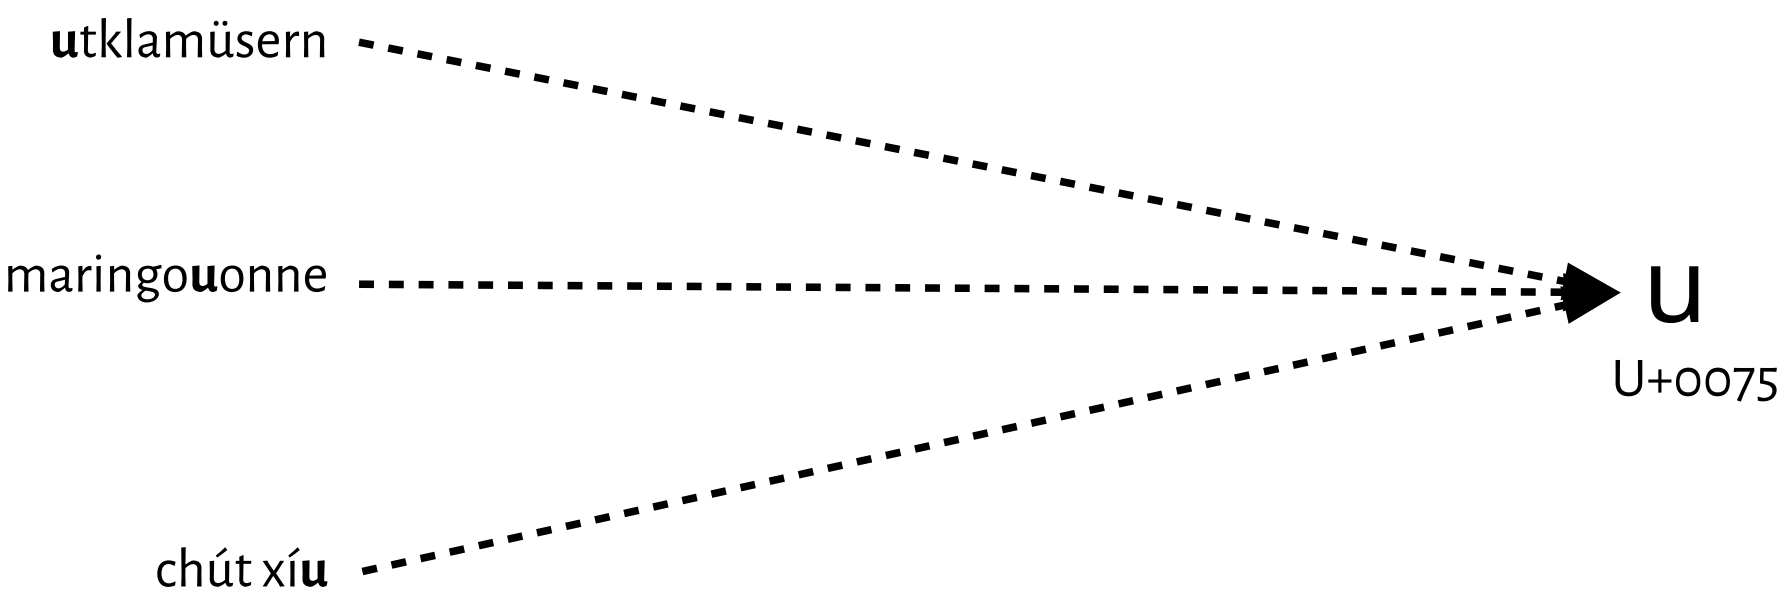
U+0D09

Tamil  உ

U+0B89

Grantha  𑌉

U+11309


utklamüsern
maringo**u**onne
chút xí**u**
u
U+0075

நிறப்பிரிகை

செயல் - அதுவே சிறந்த சொல்

கல்வி | விவாதம் | இலக்கியம் | ஆய்வு | அரசியல்

Thursday, October 28, 2010

Jean-Luc Chevillard on Tamil unicode controversy



nirappirikai.blogspot.com/2010/10/jean-luc-chevillard-on-tamil-unicode.html

ক ক ka IPA: /kə/	খ খ kha IPA: /kʰə/	গ গ ga IPA: /gə/	ঘ ঘ gha IPA: /gʱə/	ঙ ঙ ṅa IPA: /ŋə/
চ চ ca IPA: /t͡ʃə/	ছ ছ cha IPA: /t͡ʃʰə/	জ জ ja IPA: /d͡ʒə/	ঝ ঝ jha IPA: /d͡ʒʱə/	ঞ ঞ ña IPA: /ɲə/
ট ট ṭa IPA: /ʈə/	ঠ ঠ ṭha IPA: /ʈʰə/	ড ড ḍa IPA: /ɖə/	ঢ ঢ ḍha IPA: /ɖʱə/	ণ ণ ṇa IPA: /ɳə/
ত ত ta IPA: /t̪ə/	থ থ tha IPA: /t̪ʰə/	দ দ da IPA: /d̪ə/	ধ ধ dha IPA: /d̪ʱə/	ন ন na IPA: /nə/
প প pa IPA: /pə/	ফ ফ pha IPA: /pʰə/	ৱঁ ৱঁ ba IPA: /bə/	ভ ভ bha IPA: /bʱə/	ম ম ma IPA: /mə/
য য ya IPA: /jə/	ব ব ra IPA: /rə/	ন ন la IPA: /lə/	র র va IPA: /ʋə/	শ শ śa IPA: /ʃə/
ষ ষ ṣa IPA: /ʂə/	স স sa IPA: /sə/	হ হ ha IPA: /ɦə/		

en.wikipedia.org/wiki/Tirhuta_script

Unicode

mybank.com

Unicode

mybank.com

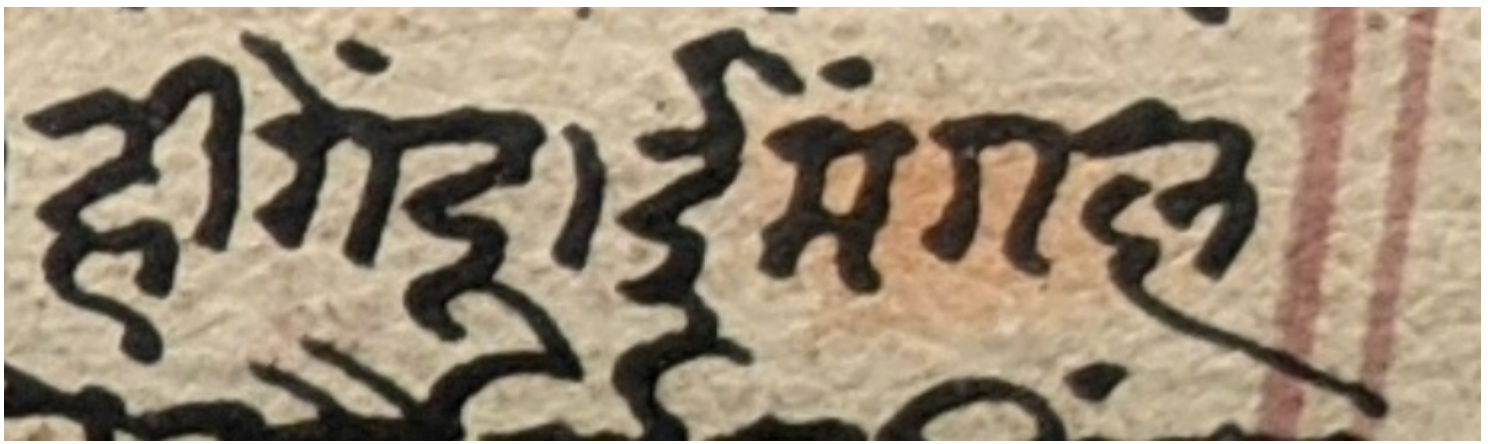
U+0061 (Latin Small Letter A)

mybank.com

U+0430 (Cyrillic Small Letter A)

“International Domain Name Homograph Attack”

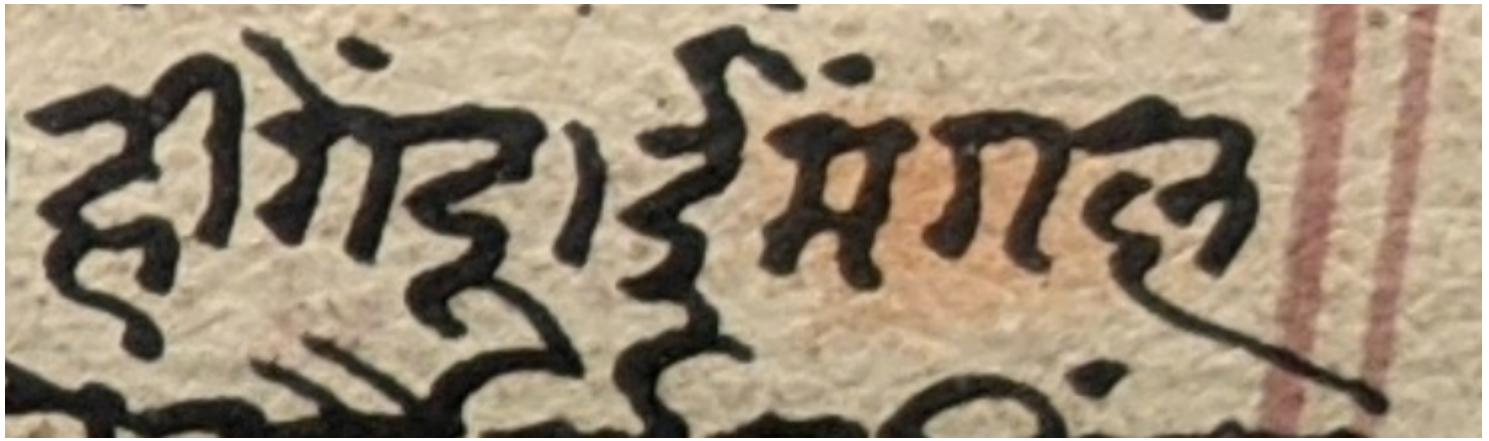
Unicode



British Library, IO SAN 1758, 1v.

हीगेंडू । ई मंग?

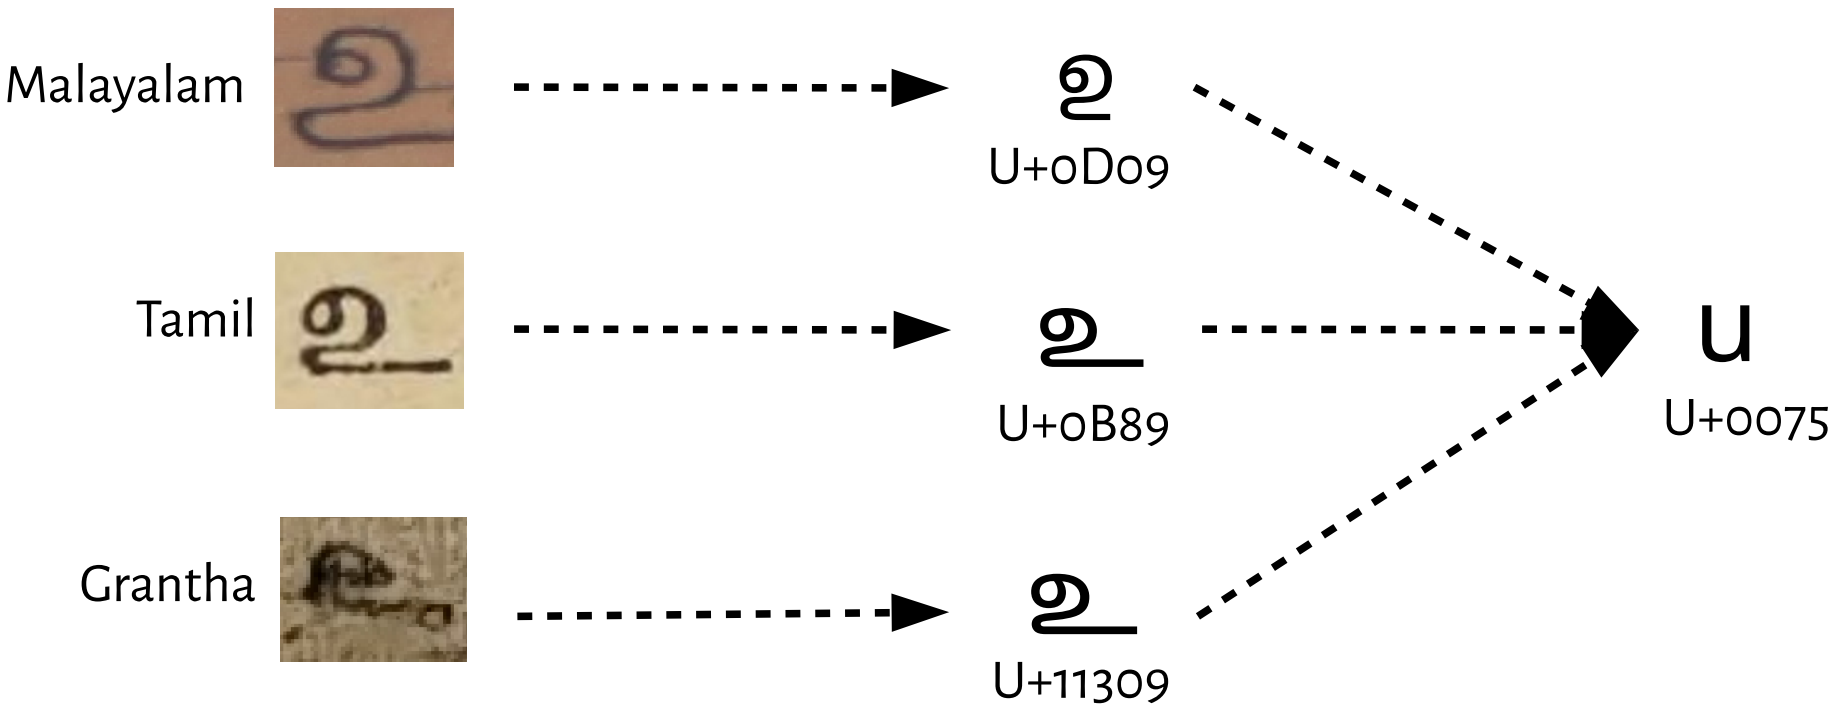
Unicode



British Library, IO SAN 1758, 1v.

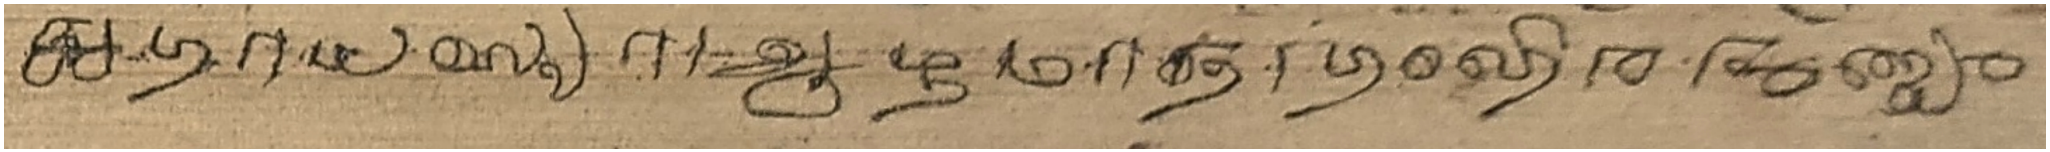
hīgeṃḍū | ī maṃgaḷa…

Transliteration



Transliteration

Tamil



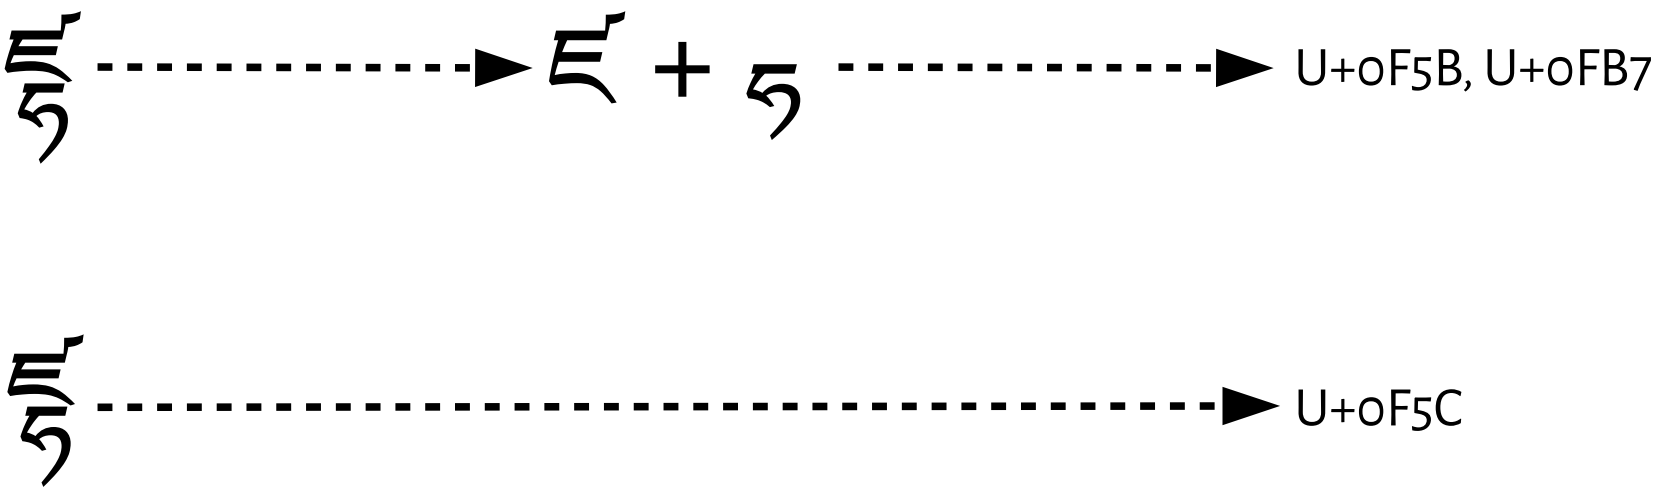
Sanskrit

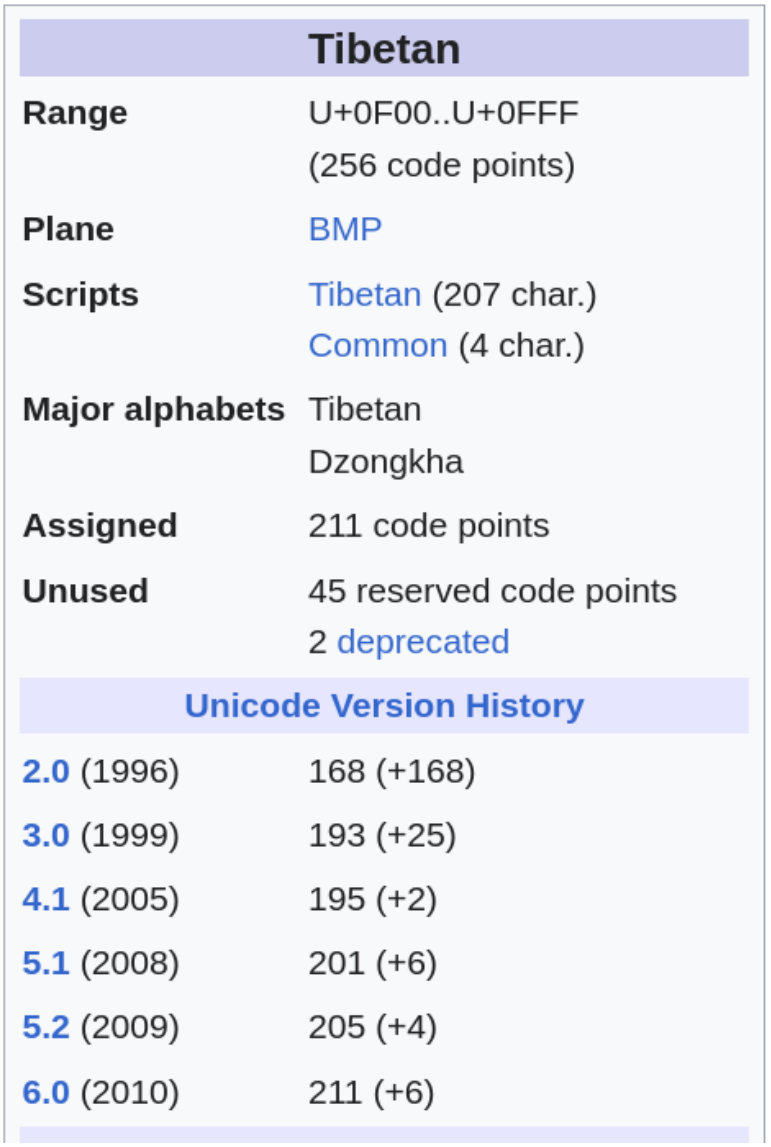
Telugu

BnF Sanscrit 622, 1r.

agādhasyā | āḻamāna | gaṃbhīranuṇḍu…

Transliteration





Tibetan	
Range	U+0F00..U+0FFF (256 code points)
Plane	BMP
Scripts	Tibetan (207 char.) Common (4 char.)
Major alphabets	Tibetan Dzongkha
Assigned	211 code points
Unused	45 reserved code points 2 deprecated
Unicode Version History	
2.0 (1996)	168 (+168)
3.0 (1999)	193 (+25)
4.1 (2005)	195 (+2)
5.1 (2008)	201 (+6)
5.2 (2009)	205 (+4)
6.0 (2010)	211 (+6)

en.wikipedia.org/wiki/Tibetan_(Unicode_block)

Übungen zu Lektion 8

๑ ཀུལ་པོ་སྐྱེང་རྒྱ་ཆེན་པོས་དཀྱུ་བོ་ཁྱིཀ་པ་ཆེན་པོ་ས་བསད་དོ །
๒ བློས་ཅི་ཏན་པོ་རོམ་ཏུན་རྣམས་ཀྱིས་རལ་གྲིས་བསད་པ་དེ་མི་རྣམས་ཀྱིས་དེ་ནི་སྨྲ་ཐབ་ཤོཊ་ཞེས་སྨྲའོ །
๓ ཁྱང་བདག་གིས་ཪོས་པ་རྣམས་ནི་ཏྲིགས་པོ་དེས་ཚེགས་བར་མ་བསྡུངས་པ །
๔ བློས་ཅི་རིཏས་བཅང་པོ་ཡིན །
๕ རིན་ཆེན་དངུལ་སྐྱོང་བཏུ་བཏུ་རྣམས་ཀྱིས་ཪོས་པ་སྐྱར་ཏོ །
๖ བདག་ནི་ཁྱིཁ་པ་ཆེན་པོ་རྣམས་བྱས་པས་བྱང་ཆུབ་མི་ཐོབ་པོ །
๗ ཁ་ཅིན་ཚེགས་བར་མ་དབྱངས་པ་ནི་བཁ་ཤེས་པ་མ་བྱིས་ཤིཁ །
๘ ཁ་ཏན་པོས་སྐྱ་ཟབ་པོས་ལས་ཁྱིཁ་པ་མ་བྱེས་ཤིཁ་ཅེས་སྨས་པས་བདག་གིས་རྟུས་པ་ཅི་ཡོད་པས་ལས་དཀི་བ་རྣམས་བྱའོ །
๙ མཆོད་རྟེན་རིན་ཆེན་བཟང་པོ་བདུན་པ་ཁས་པས་མཆོད་ཅིཁ །
๑๐ ཆིཁ་བདག་གིས་སྨྲས་པ་བཅོས་མ་ཡིན་ཏེ། བདག་གིས་སྨྲས་པ་བདེན་པ་ཡིན །
๑๑ བྱམ་ཅི་ཀུ་ཁར་པ་རྣམས་ཀྱིས་འདི་སྐད་ཅེས་སྨྲས་པོ །པ་རྣམས་མ་སོད་ཅིཁ །
๑๒ ཁྱིང་པ་མོ་མིཁ་མི་མཐོང་བ་འདི་ཁ་ནི་ཆ་རིང་པོ་ཡིན །
๑๓ དབུ་པོ་ལྷར་མ་རྣམས་ཀྱིས་དོཁས་པ་ཆེན་པོས་འདི་སྐད་ཅེས་སྨྲས་པོ །ཀྱི་ཀུལ་པོ་བདག་ཅག་མ་སོད་ཅིཁ །
๑๔ ཁྱིས་པ་རྣམས་རྒྱར་ཆོཁ །སྤ་ཁིཁ་ཉམས །
๑๕ ཀུ་མཆོ་ནི་ཆུ་ཁཀྱིང་ཟབ་པོའམ་མི་ཟབ་པོ །

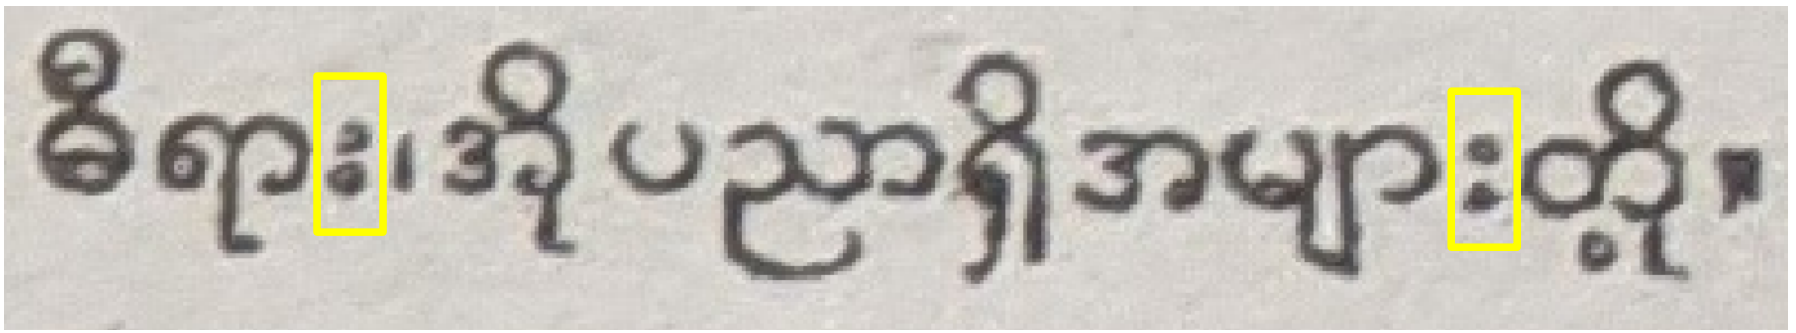
Wörterverzeichnis zu Lektion 8

ཀྱེ་བ་	stehlen, rauben	འཇུག་པ་	eintreten lassen
ཀྱེན་པོ་	Dieb	འཇོམས་པ་	schlagen, vernichten
གཞོལ་པ་	Ergebenheit, Hingabe	ཉོ་བ་	kaufen
ཁྲལ་	Messer	ཉོས་	Perfektstamm zu ཉོ་བ་
གླང་	Ochse	གཏམ་	Rede
དཀི་བ་	heilvoll	སྐྱོད་པ་	loben, preisen
ངན་པ་	schlecht	སྐྱབས་	Stärke
དངུལ་	Geld, Silberstück	སྐྱར་བ་	verlorengehen
ཅི་	was?	བསྐྱོད་	Perfektstamm zu སྐྱོད་པ་
བཅོས་	Perfektstamm zu འཇོམས་པ་	བསྐྱོད་པ་	Lob, Preis
ཆགས་པ་	Leidenschaft	ཐུབ་པ་	imstande sein zu, jem. gleichkommen an (Instr.)
ཆགས་བྲལ་	leidenschaftslos	ཐོབ་པ་	erlangen
ཆུབ་པ་	eindringen in	མཐུ་	Macht, Kraft
རྩོལ་	Raub, Diebstahl	རྣགས་པ་	sich fürchten vor (Instr.)
རྩོལ་ཀྱེན་	Dieb		
མཆོད་པ་	verehren		

Lehrbuch der klassischen tibetischen Schriftsprache, Hahn 1971, 59. Via Baedermaeker 2023.

Transliteration

Pali



Sanskrit

Burmese

Aggadhammābhivaṃsa 1935, 19.

dhīrāḥ | ’uipaññārhiamyā”tui' ||

“deep orthography”

In summary

- when to transcribe in the “same” script as the document:
  - when that script exists in Unicode
  - when working in a single language, closely tied to a single script

- when to transliterate:
  - when the script doesn’t exist in Unicode
  - when working with multiple languages, multiple scripts
  - when you want to decompose consonants and vowels

IIIF

- **I**nternational **I**mage **I**nteroperability **F**ramework
  - technology for sharing images over the Internet
  - allows us to link our annotations to images anywhere in the world

IIIF

- IIIF manifest
  - list of images available for an item
  - look for this icon: 
  - for archive.org items, see https://iiif.io/guides/guides/archive.org/

Next week

- questions/comments/bugs(!) when using the TST editor
- show & tell your manuscript

- more philosophy blah blah
- Kierkegaard's *The Wife of the Orientalist*
- adding rich annotations with TEI XML